

UNIVERSIDAD SERGIO ARBOLEDA

TALLER DE REGRESIÓN LINEAL: INGRESO MENSUAL FRENTE A LA EDAD

Inteligencia Artificial

Camilo Andrés Díaz García

Universidad Sergio Arboleda
Facultad de Sistemas e Ingeniería
Bogotá D.C., 2026

Índice

1. Introducción **2**

2. Datos y preparación **2**

2.1. Descripción de los datos 2

2.2. Control de calidad 2

3. Metodología **4**

3.1. Decisiones de diseño 4

3.2. Implementación 4

4. Resultados **5**

4.1. Relación entre la edad y el ingreso 5

4.2. Modelo ajustado 6

4.3. Evaluación del modelo 7

4.4. Análisis de residuales 9

4.5. Predicciones 10

5. Costo computacional **10**

5.1. Entorno de ejecución 11

5.2. Tiempo de ejecución 11

5.3. Memoria y peso en disco 12

5.4. Escalamiento 13

6. Conclusiones **13**

1 Introducción

Este informe presenta el ajuste de un modelo de regresión lineal simple que estima el ingreso mensual a partir de la edad. Los datos provienen del archivo `data.xlsx`, con 10.280 registros.

El desarrollo se realizó en un cuaderno de Jupyter con la librería scikit-learn, ejecutado de forma local y compatible con Google Colab. La ejecución local permitió medir el costo computacional del modelo. El documento recoge la metodología, la implementación, los resultados y el costo computacional, y cierra con las conclusiones.

2 Datos y preparación

2.1 Descripción de los datos

El archivo contiene varias variables. Para el modelo se tomaron dos columnas de la primera hoja del libro: `edad`, en años, e `ingreso_mensual`. La segunda hoja del libro está vacía.

Estadístico	**Edad (años)**	**Ingreso mensual**
Conteo	10.280	10.280
Media	39,7	7.362,4
Desviación estándar	14,0	5.897,3
Mínimo	12	1.000
Primer cuartil	28	3.870
Mediana	39	6.000
Tercer cuartil	50	9.000
Máximo	98	81.000

Tabla 1. Estadísticos descriptivos de las variables del modelo. Elaboración propia.

2.2 Control de calidad

La revisión de los datos arrojó lo siguiente:

- No hay valores nulos en las dos columnas utilizadas.
- No hay ingresos menores o iguales a cero.
- Hay 573 registros con ingresos sobre 16.695, el límite superior calculado con el rango intercuartílico. Se conservan, porque corresponden a ingresos altos plausibles y el taller pide ajustar el modelo con los datos completos.

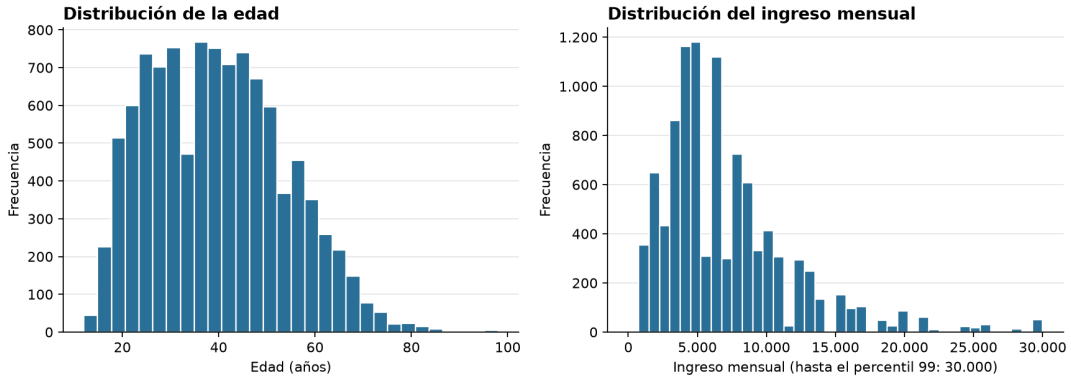


Figura 1. Distribución de la edad y del ingreso mensual. Elaboración propia.

Cómo leerla.

- **Estructura:** dos histogramas; a la izquierda la edad y a la derecha el ingreso mensual, con la variable en el eje horizontal y la frecuencia en el vertical. El ingreso se muestra hasta el percentil 99 (30.000).
- **Qué se ve:** la mitad central de las edades está entre 28 y 50 años, con registros desde 12 hasta 98. El ingreso tiene asimetría hacia la derecha: la media (7.362,4) supera a la mediana (6.000) y hay valores hasta 81.000.
- **Por qué:** la asimetría y los ingresos altos anticipan errores grandes en algunas predicciones, lo que afecta sobre todo al RMSE.

3 Metodología

3.1 Decisiones de diseño

Elemento	Decisión	Motivo
Variable predictora	`edad`, en años	Es la variable que pide el taller
Variable objetivo	`ingreso_mensual`	Es el valor que se desea predecir
Partición	80 % entrenamiento (8.224 registros) y 20 % prueba (2.056 registros)	Evaluar con datos que el modelo no vio al entrenar
Semilla	42	Hacer reproducible la partición
Modelo	`LinearRegression` de scikit-learn	Ajusta la recta por mínimos cuadrados ordinarios
Modelo de referencia	`DummyRegressor` con la media del ingreso de entrenamiento	Medir si la recta mejora a la predicción más simple
Modelo de contraste	Polinomio de grado 2 en la edad	Revisar si la linealidad es un supuesto adecuado
Métricas	R^2, MAE y RMSE	Medir la proporción explicada y el error en las unidades del ingreso

Tabla 2. Decisiones de diseño del experimento. Elaboración propia.

3.2 Implementación

La implementación sigue estos pasos en el cuaderno:

1. **Carga.** En Google Colab se solicita `data.xlsx` mediante un cuadro de carga; en un entorno local se lee desde la carpeta del cuaderno.
2. **Selección y revisión.** Se toman las columnas `edad` e `ingreso_mensual`, se eliminan filas con nulos y se calculan los estadísticos y los controles de calidad.
3. **Partición.** Se usa `train_test_split` con una fracción de prueba de 0,20 y la semilla 42.
4. **Entrenamiento.** Se ajusta `LinearRegression` con la edad como única variable predictora y se extraen la pendiente m y el intercepto b.
5. **Evaluación.** Se calculan R^2, MAE y RMSE en entrenamiento y en prueba, junto con el modelo de referencia y el de contraste.

6. **Residuales.** Se calculan los residuales del conjunto de prueba y su promedio por grupo de edad.

7. **Predicción.** Se estima el ingreso para edades entre 20 y 65 años con una función dedicada.

8. **Costo computacional.** Se cronometra cada etapa con `perf_counter`, se mide la memoria con `tracemalloc` y se registra el peso de los archivos del taller.

4 Resultados

4.1 Relación entre la edad y el ingreso

El coeficiente de Pearson entre la edad y el ingreso es 0,0382 y el de Spearman es 0,0249. Ambos indican una asociación casi nula.

Grupo de edad	Conteo	Media	Mediana
Hasta 20 años	783	4.541	4.300
21 a 30 años	2.308	7.180	6.020
31 a 40 años	2.472	8.066	6.450
41 a 50 años	2.332	7.916	6.450
51 a 60 años	1.555	7.795	6.020
61 a 70 años	655	6.465	4.500
Más de 70 años	175	4.587	3.440

Tabla 3. Ingreso mensual por grupo de edad. Elaboración propia.

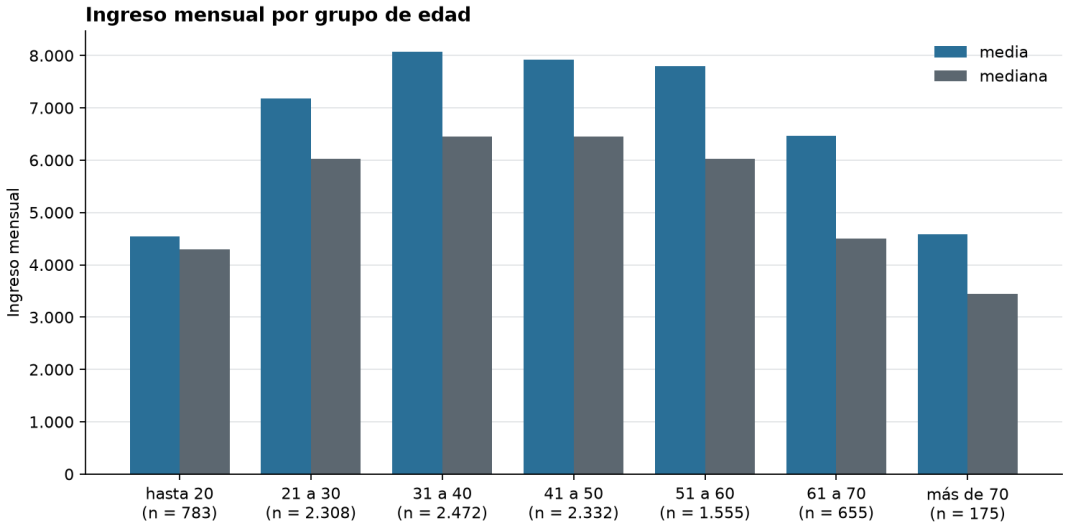


Figura 2. Media y mediana del ingreso mensual por grupo de edad. Elaboración propia.

Cómo leerla.

- **Estructura:** barras agrupadas por grupo de edad; en cada grupo, la barra azul es la media y la gris es la mediana. Bajo cada grupo se indica el número de registros.
- **Qué se ve:** el ingreso medio sube de 4.541 en el grupo de hasta 20 años a 8.066 en el de 31 a 40, se mantiene cerca de 7.900 y 7.800 hasta los 60 años y baja a 6.465 y 4.587 en los dos grupos siguientes. La media supera a la mediana en todos los grupos.
- **Por qué:** la forma de U invertida muestra que el ingreso no crece de manera constante con la edad, que es lo que supone una recta (Tabla 3).

4.2 Modelo ajustado

El entrenamiento con 8.224 registros produjo la recta

$$\hat{y} = 16{,}07\,x + 6.718{,}52 \tag{1}$$

donde x es la edad en años, m es la pendiente, b es el intercepto y $\hat{y}$ es el ingreso mensual estimado.

Parámetro	**Valor estimado**
Pendiente, m	16,07
Intercepto, b	6.718,52

Tabla 4. Parámetros del modelo lineal. Elaboración propia.

La pendiente indica que cada año adicional de edad se asocia con 16,07 unidades más de ingreso mensual, unas 161 por década.

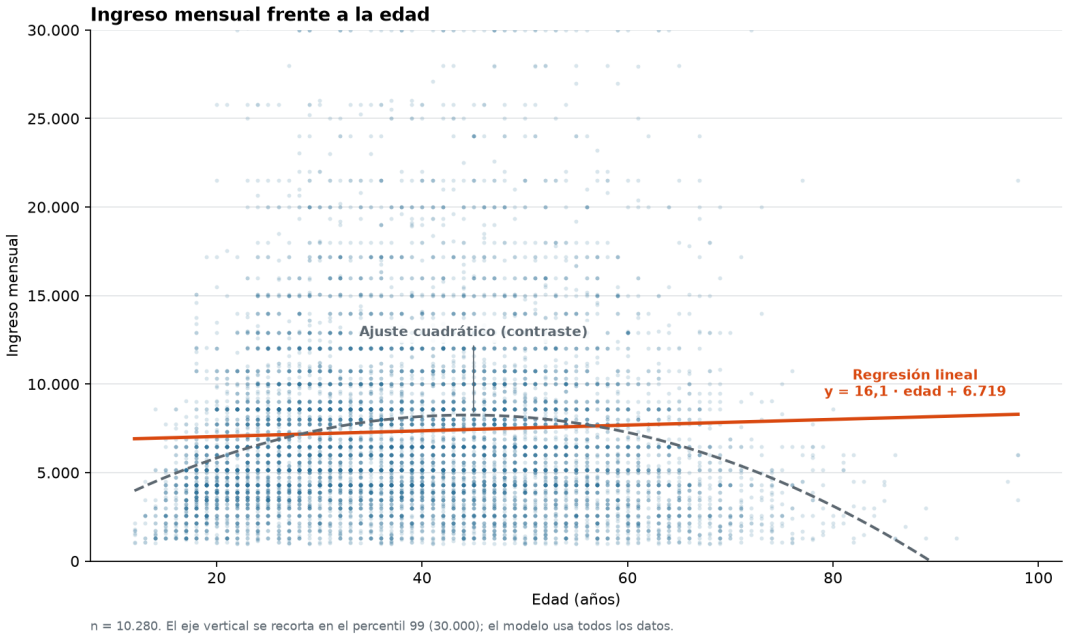


Figura 3. Dispersión de los datos y recta de regresión, con el ajuste cuadrático como contraste. Elaboración propia.

Cómo leerla.

- **Estructura:** nube de puntos con la edad en el eje horizontal y el ingreso mensual en el vertical. La línea naranja continua es la recta ajustada y la gris discontinua es el ajuste cuadrático.
- **Qué se ve:** la recta es casi horizontal, de 6.900 aproximadamente a los 12 años hasta 8.300 a los 98. La curva cuadrática sube hasta cerca de los 45 años y luego desciende. Los puntos se dispersan en una banda amplia alrededor de ambas líneas.
- **Por qué:** la dispersión alrededor de la recta es la causa del bajo R^2, y la curvatura de la línea gris muestra que la recta omite el patrón del ingreso según la edad.

4.3 Evaluación del modelo

Modelo	R^2	**MAE**	**RMSE**
Lineal (entrenamiento)	0,0014	3.810	5.950
Lineal (prueba)	0,0015	3.881	5.656
Cuadrático (prueba)	0,0280	3.765	5.581
Referencia: media (prueba)	≈ 0	3.883	5.661

Tabla 5. Métricas de desempeño. Elaboración propia.

Cómo leerla.

- **Estructura:** una fila por modelo y conjunto de datos, y una columna por métrica.
- **Qué se ve:** el modelo lineal alcanza un R^2 de 0,0015 en prueba. Su MAE (3.881) es casi igual al de la referencia (3.883) y su RMSE (5.656) apenas es menor que el de la referencia (5.661). El R^2 de la referencia es $-0{,}00002$. El modelo cuadrático llega a 0,0280 de R^2 y a 3.765 de MAE.
- **Por qué:** comparar con la referencia indica si la recta aporta información. El parecido entre entrenamiento y prueba descarta el sobreajuste.

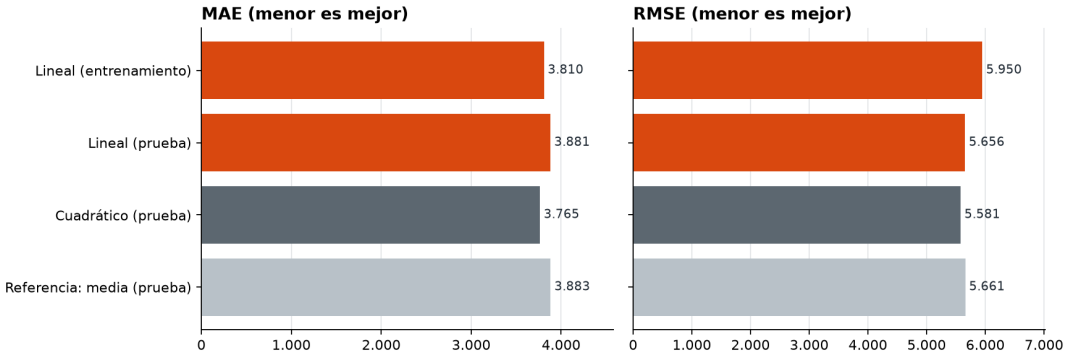


Figura 4. Comparación del MAE y del RMSE entre modelos. Elaboración propia.

Cómo leerla.

- **Estructura:** dos paneles de barras horizontales, uno para el MAE y otro para el RMSE, con una barra por modelo y el valor al final de cada barra.
- **Qué se ve:** las barras de la recta y de la referencia tienen casi la misma longitud en ambas métricas. La barra del modelo cuadrático es algo más corta.
- **Por qué:** una barra más corta significa menor error; la diferencia mínima entre la recta y la referencia confirma que la edad, con una relación lineal, casi no mejora la predicción.

4.4 Análisis de residuales

Grupo de edad	Residual medio
Hasta 20 años	−2.403
21 a 30 años	132
31 a 40 años	680
41 a 50 años	746
51 a 60 años	−96
61 a 70 años	−1.348
Más de 70 años	−2.855

Tabla 6. Residual medio del modelo lineal por grupo de edad en el conjunto de prueba. Elaboración propia.

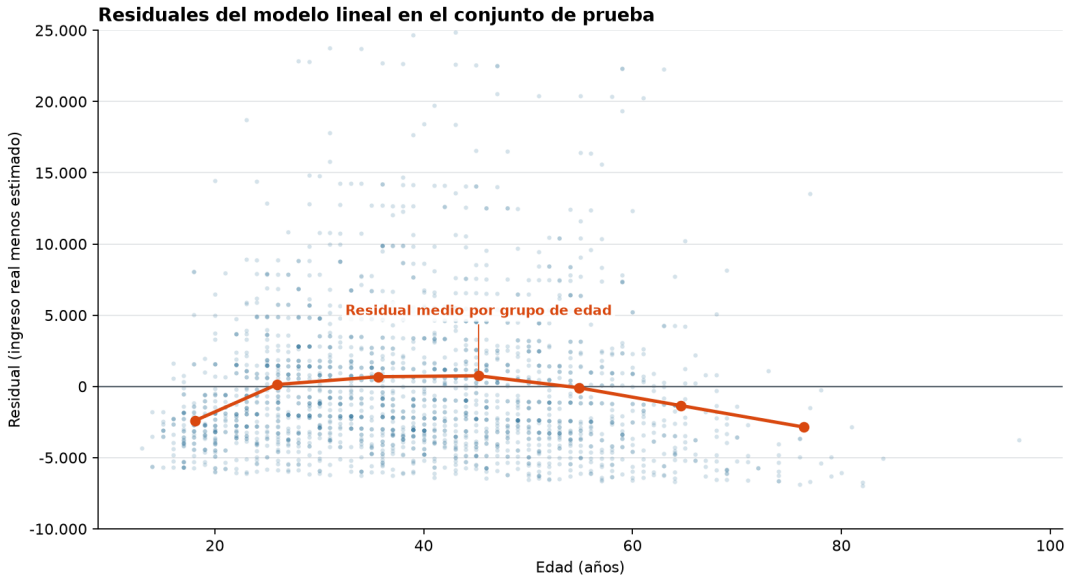


Figura 5. Residuales del modelo lineal en el conjunto de prueba. Elaboración propia.

Cómo leerla.

- **Estructura:** cada punto es un registro de prueba, con la edad en el eje horizontal y el residual (ingreso real menos estimado) en el vertical. La línea naranja une el residual medio de cada grupo de edad y la línea gris marca el cero.
- **Qué se ve:** la línea naranja no se mantiene sobre el cero: está por debajo en los grupos de menor y de mayor edad, y ligeramente por encima entre los 21 y los 50 años (Tabla 6).
- **Por qué:** un modelo bien especificado tendría residuales medios cercanos a cero en todas las edades. El patrón observado indica que la recta sobrestima el ingreso de las personas más jóvenes y de las mayores.

4.5 Predicciones

Edad (años)	Ingreso estimado (lineal)	Ingreso estimado (cuadrático)
20	7.040	5.826
25	7.120	6.718
30	7.201	7.406
35	7.281	7.891
40	7.361	8.173
45	7.442	8.251
50	7.522	8.127
55	7.602	7.799
60	7.683	7.268
65	7.763	6.534

Tabla 7. Ingreso mensual estimado según la edad. Elaboración propia.

Cómo leerla.

- **Estructura:** una fila por edad, con la estimación del modelo lineal y la del modelo de contraste.
- **Qué se ve:** el modelo lineal pasa de 7.040 a los 20 años a 7.763 a los 65, un aumento de 723 en 45 años. El modelo cuadrático estima 5.826 a los 20 años, alcanza 8.251 a los 45 y baja a 6.534 a los 65.
- **Por qué:** las dos columnas muestran cuánto cambia la estimación al incorporar la curvatura, sobre todo en los extremos del rango de edades.

5 Costo computacional

Esta sección resume el tiempo, la memoria y el peso en disco del taller. Las mediciones se tomaron en una ejecución local del cuaderno, en el equipo de la Tabla 8. Los valores dependen del equipo y de la carga que tenía en ese momento, por lo que cada etapa se repitió varias veces y se reporta el promedio con su desviación estándar.

5.1 Entorno de ejecución

Componente	Detalle
Procesador	Intel Core i7-8750H a 2,20 GHz, 6 núcleos y 12 procesadores lógicos
Memoria RAM	15,9 GiB
Sistema operativo	Windows 11 Home
Python	3.14.3
NumPy y pandas	2.5.2 y 3.0.5
scikit-learn	1.9.0

Tabla 8. Equipo y versiones usados en la medición. Elaboración propia.

Cómo leerla.

- **Estructura:** una fila por componente del equipo o de la pila de software.
- **Qué se ve:** un equipo con procesador Intel Core i7-8750H, 15,9 GiB de RAM y Windows 11 Home, con Python 3.14.3 y scikit-learn 1.9.0.
- **Por qué:** los tiempos de la sección siguiente solo son comparables con ejecuciones en un equipo de características similares.

5.2 Tiempo de ejecución

Etapa	Repeticiones	Media (ms)	Desviación (ms)
Lectura de `data.xlsx`	5	558,195	34,784
Partición 80/20	200	1,136	0,092
Entrenamiento lineal	200	1,355	0,089
Entrenamiento cuadrático	200	2,673	0,094
Predicción sobre la prueba	200	0,667	0,026
Evaluación (R^2, MAE, RMSE)	200	2,292	0,135

Tabla 9. Tiempo de ejecución por etapa. Elaboración propia.

Cómo leerla.

- **Estructura:** una fila por etapa del flujo de trabajo; la media y la desviación estándar están en milisegundos.
- **Qué se ve:** el entrenamiento del modelo lineal toma 1,355 ms y su predicción sobre las 2.056 filas de prueba, 0,667 ms. El ajuste cuadrático tarda 2,673 ms, casi el doble. La lectura del archivo Excel toma 558,195 ms, unas 412 veces el tiempo del entrenamiento lineal.
- **Por qué:** la etapa más costosa es la lectura de los datos, no el modelo. Las desviaciones de las etapas del modelo son menores de 0,14 ms, de modo que el tiempo es estable entre repeticiones.

El cuaderno transcurrió en 7,7 s hasta el final de la medición. De ese tiempo, cerca de 4,4 s corresponden a las repeticiones de la propia medición (5 lecturas del archivo y 200 repeticiones de cada una de las demás etapas); el resto incluye la lectura inicial, los gráficos y el entrenamiento.

5.3 Memoria y peso en disco

Concepto	Valor
Tabla de datos en memoria (10.280 filas)	160,8 KiB
Pico de memoria al ajustar el modelo lineal	263,9 KiB
Memoria del proceso de Python en ese punto	240,6 MiB

Tabla 10. Uso de memoria. Elaboración propia.

Cómo leerla.

- **Estructura:** una fila por medición de memoria, con su unidad.
- **Qué se ve:** la tabla de datos ocupa 160,8 KiB y el ajuste lineal alcanza un pico de 263,9 KiB. El proceso completo de Python usa 240,6 MiB.
- **Por qué:** la memoria del modelo es pequeña; la cifra del proceso es mucho mayor porque incluye el intérprete y las librerías cargadas.

Archivo	Peso (KiB)
`taller_regresion_lineal.ipynb`	410,6
`data.xlsx`	362,2
`fig_distribuciones.png`	52,0
`fig_grupos_edad.png`	46,7
`fig_regresion.png`	185,5
`fig_residuales.png`	105,3
`fig_errores.png`	45,4
Total	**1.207,7**

Tabla 11. Peso en disco de los archivos del taller. Elaboración propia.

Cómo leerla.

- **Estructura:** una fila por archivo y una última fila con el total, en kibibytes.
- **Qué se ve:** el cuaderno ejecutado pesa 410,6 KiB y los datos, 362,2 KiB. Las cinco figuras suman 434,9 KiB. En conjunto, los siete archivos ocupan 1.207,7 KiB, cerca de 1,2 MiB.
- **Por qué:** el peso total es pequeño y permite entregar el taller en un solo archivo comprimido y publicarlo en un repositorio sin problema.

5.4 Escalamiento

El taller no midió conjuntos de datos de mayor tamaño. Por la forma del algoritmo (mínimos cuadrados con una sola variable predictora), se espera que el tiempo de entrenamiento y de predicción crezca de forma aproximadamente lineal con el número de registros, y que la memoria adicional crezca en la misma proporción. Esta es una expectativa teórica, no un resultado medido.

6 Conclusiones

- **Modelo ajustado.** La recta obtenida es $\hat{y} = 16{,}07\,x + 6.718{,}52$. Cada año adicional de edad se asocia con 16,07 unidades más de ingreso mensual, unas 161 por década.
- **Capacidad predictiva.** En el conjunto de prueba el R^2 es 0,0015: la edad explica el 0,15 % de la variación del ingreso. El MAE es 3.881 frente a 3.883 del modelo que siempre predice la media, de modo que la recta no mejora la predicción de referencia.
- **Generalización.** El R^2 de entrenamiento (0,0014) y el de prueba (0,0015) son casi iguales. El bajo desempeño no se debe al sobreajuste, sino a que la edad, por sí sola y con una relación lineal, aporta muy poca información sobre el ingreso. Esto corresponde a un modelo con varianza baja y error alto también en entrenamiento

(subajuste): la recta es demasiado simple para la relación, y parte del error es ruido que la edad, por sí sola, no explica.

- **Forma de la relación.** El ingreso medio sube de 4.541 en el grupo de hasta 20 años a 8.066 en el de 31 a 40, se mantiene cerca de 7.900 y 7.800 hasta los 60 y baja a 6.465 y 4.587 en los dos grupos siguientes. Los residuales medios siguen ese patrón: son negativos en el grupo de hasta 20 años (-2.403) y en el de más de 70 (-2.855), y positivos entre los 21 y los 50 años. Una recta no puede representar una relación con forma de U invertida.

- **Modelo de contraste.** El término cuadrático eleva el R^2 a 0,0280 y reduce el MAE a 3.765. La mejora, junto con el patrón de los residuales, es coherente con que la linealidad sea una limitación, pero el 97 % de la variación sigue sin explicarse.

- **Predicciones.** El modelo lineal estima 7.040 a los 20 años y 7.763 a los 65, una diferencia de solo 723 en 45 años. Estas estimaciones sobrestiman el ingreso de las personas más jóvenes y de las mayores, y deben interpretarse como una tendencia promedio, no como un valor individual.

- **Costo computacional.** En un equipo con procesador Intel Core i7-8750H y 15,9 GiB de RAM, el entrenamiento del modelo lineal toma 1,355 ms, la predicción sobre la prueba 0,667 ms y el pico de memoria al ajustar es de 263,9 KiB. La lectura del archivo Excel (558,195 ms) es la etapa más lenta. Los siete archivos del taller suman cerca de 1,2 MiB. El costo es bajo: la limitación del modelo es la información que aporta la edad, no los recursos de cómputo.

- **Alcance.** El archivo incluye otras variables (nivel educativo, años de escolaridad y sexo) que no se usaron, porque el taller solicita la relación entre ingreso y edad. Su aporte no se evaluó.